

الرحيم الرحمن الله بسم

مغز گلیومای های توموری درجه تایین و بندی طبقه: موضوع
سطح تعیین فعال های کانتور و ای آر ام تصاویر از استفاده با

حیدری مریم: دانشجو نام

اسلامی دکتر: استاد نام

- است و (MIP) تقسیم بندی یک عنصر اساسی در پردازش تصویر پزشکی برای کمک به تفسیر و استفاده بالینی به طور گسترده مورد بررسی و توسعه در این مقاله روشی برای تقسیم توده های غیر طبیعی یا قرار گرفته است تومورها در تصاویر پزشکی مورد بحث قرار می گیرد که هم قوی و هم و تکنیک های سطح (AC) مایک روش مبتنی بر کانتور فعال. مؤثر است تنظیم شده برای تشخیص بدخیمی در تصویربرداری با رزونانس مغناطیسی برای. را پیشنهاد کردیم (CT)، ماموگرافی و توموگرافی کامپیوتری (MRI) تقسیم توده های بدخیم، رویکرد کانتور فعال، عملکرد انرژی، روش سطح 160 این سیستم با استفاده از. پیشنهادی استفاده می شود F تنظیم و عملکرد اسکن مغز 80 ماموگرافی و 80 تصویر پزشکی از دو پایگاه داده، از جمله الگوریتم برای تقسیم بخش های مشکوک به. مورد بررسی قرار گرفت MRI % 95.71 و % 95.60، 96.25 ترتیب دارای دقت، فراخوان و دقت با افزودن این تکنیک به دستگاه های تصویربرداری بافت، صحت. است تشخیص تصاویر با حجم نسبتاً زیادی که سریع ارزیابی می شود افزایش می صرفه جویی در هزینه، صرفه جویی در وقت و دقت بالا همه مزایای. یابد. رویکردی است که آن را از سیستم های مشابه جدا می کند.

مدل کانتور فعال، که مدل مارها نیز نامیده می شود، یک چارچوب در بینایی رایانه ای است که توسط مایکل کاس

اندرو ویتکین و دمتری ترزوپولوس معرفی شده، و برای ترسیم خطوط خارجی یک شیء، از یک تصویر دو بعدی

مدل مارها در دیدگاه رایانه ای محبوب است و این مدل بطور .احتمالاً پر نویز تعریف شده است گسترده در برنامه های

کاربردی مانند ردیابی شی، تشخیص شکل، تقسیم بندی، آشکارسازی لبه و تطبیق استریو مورد استفاده قرار می گیرد.

مدل مار یک انرژی کمینه کننده و اسپلاین قابل اصلاح است که تحت تأثیر محدودیت ها و نیروهای تصویر است که

.آن را به سمت کانتورها و نیروهای داخلی متصل می کند که مقاومت در برابر تغییر شکل را دارند مدل مارها ممکن

است به عنوان یک مورد خاص از روش کلی تطبیق یک مدل ناپایدار به یک تصویر با استفاده از به حداقل رساندن

در دو بعد، مدل شکل فعال ، یک نسخه گسسته این رویکرد را نشان می دهد، با .انرژی درک شوند استفاده از مدل

توزیع نقطه برای محدود کردن محدوده شکل به یک دامنه صریح از یک مجموعه آموزشی یاد می مارها گل شود

مشکل پیدا کردن خطوط در تصاویر را حل نمی کنند، زیرا این روش نیاز به دانش قبلی شکل کانتورهای طراحی شده

در عوض، آنها به مکانیزم های دیگر مانند تعامل با یک کاربر، تعامل با برخی از فرایندهای .دارد درک تصویری

- سطح بالاتر یا اطلاعاتی از داده های تصویر مجاور در زمان یا فضا بستگی دارد

بخش بندی تومور مغزی گامی مهم در تشخیص بیماری و روند درمان است.
بخش بندی دستی تومورهای مغزی روشی

هدف از این مطالعه، بخش بندی خودکار تومور مغزی. زمان بر است
MRI و بررسی میزان دقت توالی های مختلف MRI تصاویر

برای این منظور، از تصاویر موجود در. در بخش بندی تومور مغزی است
برای آموزش. استفاده شده است BRATS پایگاه داده

شبکه، ۳۱۰ تصویر

و همچنین، تصاویر بخش بندی FLAIR و TIW، T2W T1ce در چهار توالی
شده مرجع استفاده

استفاده شد ResNet در این مرحله از شبکه عصبی یادگیری عمیق. شدند
60 پس از آموزش شبکه، عملیات بخش بندی روی

با توجه به نتایج به دست آمده از پارامتر شباهت،. آزمایش انجام شد MRI
عملکرد بهتری نسبت به سایر FLAIR توالی

مقدار این پارامتر. توالی ها به منظور بخش بندی تومور مغزی داشته است
۷۷ است؛ در حالی که ۰/۰ + ۱۰/۰ برابر با ۰ FLAIR برای

، $0/73 \pm 12/$ به ترتیب برابر با ۰ T1ce و T2W TIW مقدار آن برای
همچنین، توالی. ۶۲ است/۰ + ۱۷/۷۳ و ۰/۰ + 0/15

حساسیت بیشتری برای بخش بندی تومور مغزی داشته و مقدار آن FLAIR
۸۳ است، براساس نتایج این/۰ + ۱۲/ برابر با ۰

توالی قابل اعتمادتری نسبت به سایر توالی ها برای بخش FLAIR مطالعه،
بندی تومور مغزی است

مقدمه

تومورهای مغزی می توانند در شکل ها و اندازه های متداول .مختلفی ظاهر شوند و تا زمان تشخیص به اندازه کافی رشدکنند ترین نوع تومورهای مغزی در بزرگسالان گلیوم بر اساس .است که از سلول های گلیال ایجاد شده است درجه وخامت گلیوم و منشأ آن، این نوع تومور مغزی به دو و گلیوم درجه پایین (HGG)نوع گلیوم درجه بالا یک روش معمول برای .(۱)تقسیم می شود ('LGG) غربالگری تومورهای مغزی، تصویربرداری تشدید است که در آن می توان مکان تومور را ("MRI)مغناطیسی از مغز علاوه بر اینکه اساس MRIدر واقع اسکن .تعیین کرد غربالگری تومور است، برای برنامه ریزی قبل از عمل .(۲)جراحی یا پرتو درمانی نیز استفاده می شود

متداول ترین روش درمان تومورهای مغزی، جراحی
اگرچه ممکن است روش هایی نظیر پرتو درمانی و .است
شیمی درمانی نیز برای کاهش سرعت رشد تومورهایی
بخش بندی .استفاده شوند که خارج کردن آنها مشکل است
می تواند تأثیر چشمگیری MRI تومورهای مغزی در تصاویر
در تشخیص صحیح تومور و پیش بینی سرعت رشد آن و
برخی از .همچنین، برنامه ریزی برای درمان داشته باشد
تومورها مانند مننژیوم را می توان به راحتی بخش بندی کرد؛
در حالی که مشخص کردن محل تومورهایی مانند گلیوم و
همراه با) این تومورها .گلیوبلاستوم بسیار دشوارتر است
• بیشتر پراکنده اند و تضاد ضعیفی با بافت (تورم اطراف آنها
سالم اطراف خود دارند و به ساختارهایی شاخک مانند
.گسترش پیدا می کنند که بخش بندی آنها را دشوار می کند
مشکل اساسی دیگر در بخش بندی تومورهای مغزی این
است که می توانند در هر نقطه از مغز، تقریباً به هر شکل و
اندازه ای ظاهر شوند

بخش بندی تومورهای مغزی توسط رادیولوژیست های با تجربه همچنان به عنوان مرجعی استاندارد در نظر گرفته با این حال، روش های بخش بندی نیمه خودکار و می شود تمام خودکار رایانه ای، افزایش سرعت بخش بندی و همچنین، روش های تکرارپذیری نتایج را موجب می شوند بخش بندی تمام خودکار ناهماهنگی میان مشاهده گر و درون مشاهده گر را از بین می برد که ناشی از عواملی مانند اختلاف در تخصص و توجه و خطاهای ناشی از خستگی علاوه بر این، با ظهور الگوریتم های تقسیم بندی بینایی است با استفاده از شبکه های عصبی کانولوشنی، پیشرفت چشمگیری در افزایش شباهت بخش بندی در روش دستی و (۸-۴) اتوماتیک به وجود آمده است.

در سال های اخیر، محققان بسیاری روش هایی برای بخش بندی خودکار و نیمه خودکار تومورهای مغزی ارائه با توجه به موفقیت های اخیر الگوریتم های شبکه کرده اند عصبی کانولوشنی، مطالعات گسترده ای در حوزه بخش بندی خودکار تومورهای مغزی با استفاده از یادگیری عمیق انجام در سال ۲۰۱۳، اصلیان و همکاران یک (۹، ۱۰) شده است روش نیمه اتوماتیک به منظور بخش بندی تومور مغزی ارائه

در این روش ابتدا ۳۰ نمونه ژست به صورت دستی دادند

سپس برای. تومور مغزی ۱۰ بیمار را بخش بندی کردند
جلوگیری از سرگیری حافظه، از چهارمین انکولوژیست با
ادم) تجربه خواسته شد تا با توجه به پیچیدگی شکل هدف
، ۴ تا ۸ نقطه در اطراف هدف را روی سکانس های (یا تومور
در مرحله آخر، منحنی با بیشترین دقت. انتخاب کند MRI
به طور خودکار بین این نقاط درون یابی شد و بدین ترتیب
منحنی اولیه به سرعت بر اساس به. منحنی اولیه برآزش شد
حداقل رساندن تابع انرژی تکامل یافت و در نهایت به مرز
میانگین. منطقه مدنظر، حجم هدف بالینی، همگرا شد
۸۲ و میانگین پارامتر/پارامتر شباهت در این روش،
در سال ۲۰۱۶، هوایی و. (۱۱) ۹۱ بوده است / هاسدورف ۱
همکاران یک شبکه عصبی کانولوشنی برای بخش بندی
موجود در پایگاه داده MRI تومورهای مغزی تصاویر
شبکه عصبی کانولوشنی ارائه شده. آموزش دادند BRATS
از یک معماری آبخاری استفاده کرده است که نتیجه شبکه

ها روش

داده های استفاده شده از .کاربردی می باشد -این مطالعه از نوع بنیادی
یک مرجع معتبر داده ای به نام چالش قطعه بندی تومور مغزی
(Brain


مجموعه داده ی .استخراج شده اند (tumor segmentation
2018 BraTS مورد استفاده در پژوهش حاضر ، مربوط به چالش
LGG و HCG ۲۱۰ و ۷۵ بیمار MRI شامل تصاویر مولتی مدالیتیه ی
در مرحله ی نخست، به منظور قطعه بندی نواحی توموری .(۷) بود
پیش پردازش تصاویر و طراحی شبکه جهت آموزش و ارزیابی با
(Dice similarity coefficient) معیارهای ضریب تشابه دایس
حساسیت، اختصاصیت و فاصله ی هوسدروف در داده های آزمون
سپس، طبقه بندی به منظور تعیین درجه ی تومور .صورت گرفت
با پیش پردازش مجدد تصاویر بر اساس یافته های LGG و HGG
مرحله ی قطعه بندی و طراحی شبکه جهت آموزش و ارزیابی با
، حساسیت، اختصاصیت، دقت موارد(Accuracy)معیارهای صحت
هر کدام از مراحل قطعه بندی و .پیش بینی مثبت و منفی انجام شد
و کتابخانه ی کراس با TensorFlow طبقه بندی در شبکه با بستر
نسخه ی ۳۰۷۲ (Python) استفاده از زبان برنامه نویسی پایتون

و پردازنده ی گرافیکی Xeon E5-2600 سری intel پردازنده
از آزمایشگاه راهبردی فناوری های نوین در NVIDIA Tesla K80
بازه ی زمانی آبان ماه سال ۱۳۹۹ تا خرداد ماه سال ۱۴۰۰ انجام شد
به

درصد کل 60 طور مشخص، داده های آموزش در هر مرحله شامل
داده ها جهت یادگیری شبکه، ۲۰ درصد داده ها برای ارزیابی و تنظیم
پارامترهای شبکه در طول فرایند یادگیری و در نهایت ۲۰ درصد
داده های آزمون جهت ارزیابی نهایی به کار برده شد
اندازه ی تصاویر در :پیش پردازش داده ها در مرحله ی قطعه بندی
به منظور . ۲۴۰ می باشد $240 \times 155 \times 1$ BraTS2018 داده های
افزایش

۱۹۰ با حذف $190 \times 135 \times 1$ قدرت محاسباتی، کاهش ابعاد تصاویر به
مناطق حاشیه ی سیاه اطراف تصاویر و حذف برش های ابتدایی و

سپس، تصاویر هر مدالیتة با کم کردن میانگین از .انتهایی انجام شد
شدت هر پیکسل و تقسیم بر انحراف معیار در هر برش نرمال سازی
برای افزایش داده های آموزش و یادگیری بهتر، شبکه ی .گردید
.صورت گرفت (Patch-based) داده افزایی با روش مبتنی بر تکه
بنابراین، از هر برش تصویر چهار تکه حاوی تومور با اندازه ی
(شکل ۱) ۱۶۰ به صورت تصادفی استخراج شد $160 \times$



شکل ۱. معماری U-Net ارائه شده برای قطعه‌بندی گلیوما

در این مقاله، قطعه بندی: معماری و آموزش شبکه ی قطعه بندی
مشهور U-Net اتومور گلیوما بر اساس اصلاح شبکه ی
شمایی از شبکه (۸) و همکاران آماده سازی گردید Ronneberger
ی

این شبکه شامل مسیر طراحی شده، در شکل ۱ ترسیم شده است
هر کدام از مسیرها شامل رمزگذاری و رمزگشایی متقارن می باشد
در پنج بلوک کانولوشنی است تا تقارن در هر دو مسیر حفظ شود
مسیر رمز گذاری، هر بلوک دارای دو لایه کانولوشنی با ابعاد فیلتر
در انتهای هر می باشد Relu ۳، طول گام یک و تابع فعال سازی $3 \times$
با ابعاد (Max-pooling) یک از چهار بلوک اول لایه حداکثر تجمع
در مسیر رمزگشایی به ۱۲ اعمال شده است \times فیلتر و طول گام ۲
منظور

هر بلوک با یک (Feature map) افزایش ابعاد نقشه ی ویژگی
لایه ی

۲ و طول گام دو، آغاز و با \times با ابعاد فیلتر ۲ Up-convolutional
یک

لایه ی اتصال مطابق با نقشه ی ویژگی آن در مسیر رمز گذاری و
در ۳ دنبال می شود \times همچنین دو لایه ی کانولوشنی با ابعاد فیلتر ۳
۱ به کار رفته \times انتهای آخرین بلوک، یک لایه ی کانولوشنی با ابعاد ۱
لایه ی حذف تصادفی به منظور جلوگیری از پیش برآزش و . است
به منظور حفظ ابعاد خروجی (Same padding) لایه گذاری مشابه
جهت طراحی شبکه، از تابع هزینه ی . مشابه ورودی استفاده شد
و هم — اران Kermi هیبرید ارائه شده در مطالعه
استفاده گردید.

از LGG HGG آموزش مدل با انتخاب تصادفی ۲۲۰ بیمار
سپس، از هر برش. صورت گرفت 2018 BraTS مجموعه ی دادهای
۱۶۰ به عنوان xتصویر، چهار تکه حاوی تومور با اندازه ی ۱۶۰
برش برای هر 135 با توجه به تعداد. ورودی به شبکه داده شد
برای آموزش. مدالیت، ۱۸۸۰۰ تصویر برای آموزش انتخاب گردید
مدل
با اندازه ی ۱۹، تعداد دوره های اجرا پنج و الگوریتم Batch (دسته
Stochastic gradient
descend) بهینه ساز گرادیان تصادفی کاهشی
نرخ یادگیری اولیه، تکانه و ضریب فروپاشی به ترتیب. انتخاب گردید
. ۰.۰۰۱ تنظیم شد/ ۹ و ۰/۰۱، ۰/۰

در هر مدالینه: پیش پردازش داده ها در مرحله ی طبقه بندی
۳۲ پرش در ناحیه ی اطراف برش با بزرگترین اندازه ی تومور به
با. منظور افزایش دقت و کم شدن بار محاسباتی استخراج شد
بکارگیری نتایج حاصل از مرحله ی قطعه بندی تومور، پیکسل های
حاوی مناطق تومور و پیکسل های غیر توموری به ترتیب به عنوان
سپس. پیکسل های اصلی و پیکسل های زمینه در نظر گرفته شد
آموزش شبکه . ۲ ضرب گردید/شدت پیکسل های غیر توموری در
ی

و FLAIR T2 طراحی شده با سه مدالینه ی تصویری با وزن
با توجه به تعداد. به عنوان ۳ کانال ورودی صورت گرفت TIW
با چرخش LGG داده افزایی بر روی تصاویر LGG کمتر تصاویر
تعداد برش های تصاویر جهت آموزش، ارزیابی. افقی آنها انجام شد
و. آزمون شبکه به ترتیب با ۶۸۹۰، ۹۱۲ و ۹۱۲ انتخاب گردید

روشی جهت طبقه بندی تصاویر تومور مغزی با اعمال جداگانه تبدیل گسسته کسینوسی و تبدیل موجک گسسته

آنها همچنین از آنالیز آنتروپی استفاده از شبکه عصبی احتمالی ارائه داده اند و انرژی تصویر نیز به عنوان

[۱] ویژگی بهره جسته اند

CT از ماشین بردار پشتیبان برای طبقه بندی تومور مغزی تصاویر بکار گرفته اند و با بررسی دو هسته مختلف

به نتیجه RBF-SVM ماشین بردار پشتیبان به این نتیجه رسیده اند که "محل" آنها دو عامل بهتری می رسد

این ویژگی ها با را بعنوان ویژگی در نظر گرفته اند "شدت" و استفاده از پنج مستطیل و پنج نقطه از ناحیه تومور و

[۲] یا غیر تومور عکس بدست آورده شده اند

MRI در تصویر "بذری" ایده جدیدی با استفاده از انتخاب برخی نقاط که قبلاً کمتر است آن بهبود داده T1

در این روش پژوهش نقاط بذر مربوط به ناحیه شده ارائه داده اند تومور یا سایر نسوج با استفاده از ترکیبی از

ابتدا تبدیل موجک را WSFTA محققان در روش پیشنهادی خود به نام
بر تصویر اعمال کرده و سپس ویژگی

آنالیز بافت فرکتال مبتنی بر "های بافت تصویر را با استفاده از اعمال
بر تصویر تجزیه شده فرکانس "طبقه بندی

پس از آن یک شبکه عصبی پیشرو دو لایه .پایین استخراج می کنند
مغز به دو MRI برای طبقه بندی تصویر

[4] قسمت بافت نرمال و بافت غیر نرمال استفاده می شود

متوسط مربع "و "دقت طبقه بندی "تحلیل گران استفاده از معیارهای
نشان داده اند که روش "MSE خطا

ماتریس هم رخدادی سطح خاکستری "پیشنهادی در مقایسه با روش
وروش ویژگی بافت هارلیک "GLCM

شبکه عصبی کوپل "روشی بر مبنای استفاده از . عملکرد بهتری دارد
توسط سوباشینی "PCNN شده با پالس

وساهو ارائه شده است

در اینجا ، ابتدا مرحله پیش پردازش شامل رفع نویز ، بهبود کمتر است و همچنین حذف آرتیفکت های ناشی از

کیفیت تصویر برداری روی تصویر اعمال می شود و سپس ویژگی های مختلفی مانند شدت پیکسل ها، لبه ها

عمل بخش بندی PCNN و بافت استخراج شده و با استفاده از شبکه تصویر به دو بخش حاوی تومور انجام می

برای تشخیص تومور مغزی از الگوریتم اصلاح شده ماشین .شود در این پایان نامه .بردار پشتیبان استفاده شده است

مغز MRI جهت تشخیص ظهور تومور ها در تصاویر (SVM) روش برای بهبود عملکرد .توسعه داده می شود

SLFA SVM در این پایان نامه، الگوریتم ماشین بردار پشتیبان به توسعه داده شده است که باعث افزایش میزان

[6]کارایی سیستم گردیده است

با استفاده از طبقه بندی هایبیرید MRI طبقه بندی سرطان مغزی در این پایان نامه یک سیستم .صورت گرفته است

مغز را ارائه می MRI برای تشخیص تصاویر طبیعی و غیر طبیعی [۷]الگوریتم هایبیرید استفاده شده است .دهد

پژوهشگران یک تکنیک تقسیم بندی تصویر برای شناسایی تومور تکنیک های .ارائه کرده اند MRI توسط

.آستانه سازی موجود نتایج متفاوتی در هر تصویر تولید کردند. بنابراین برای رسیدن به یک نتیجه رضایت بخش

در تصویر تومور مغزی، آن ها یک روش ارائه کرده اند که یافتن [۲۱] تومور به طور منحصر به فرد انجام شد

محققان روشی مبتنی بر کامپیوتر برای شناسایی دقیق محدوده تومور ، ارائه MRI در مغز توسط تصویر های

در اینجا طبقه بندی بر روی تصویر تومور مغزی انجام .کرده اند گرفته است تا معلوم شود که تومور از نوع خوش

مراحل موجود در الگوریتم پیشنهادی شامل .خیم یا بدخیم است پردازش، تقسیم بندی تصویر، استخراج

خصوصیات و طبقه بندی تصویر از طریق تکنیک های شبکه عصبی در نهایت، با استفاده از تکنیک .می باشد

[۲۲] محدوده مورد نظر، حدود تومور مکان یابی شده است

مغز به منظور MRI برای تقسیم بندی CSM اندیشمندان یک الگوریتم

یافتن منطقه دقیق تومور مغزی پیشنهاد

ها یافته

MI بستگی فضایی مقادیر شدت تصویر ، در تغییرات خطی مقادیر حاصل خواهد شد ، بدین معنی که در

همسایگی نقطه ی پارامتری تبدیلات واقعی ، مکان های حداکثر وجود ندارد که ما را از صحیح بودن روش به کار گرفته شده مطمئن کند.

REF تغییر یافته (FLOAT) نتایج آمار تطابق تصاویر همگن 1-4 جدول (می باشد X و Y بر حسب مقادیر

$\sigma_{\pm \bar{L}}$		FLOAT	th	y	x	REF
$1/80 \pm 1/80$	x					
$1/88 \pm 1/88$	y	CT11	$\cdot/88$	11	11	CT1
$\cdot/88 \pm \cdot/88$	th					
$1/90 \pm 1/90$	x					
$1/90 \pm 1/90$	y	CT22	$\cdot/88$	11	11	CT2
$\cdot/90 \pm \cdot/90$	th					
$2/90 \pm 2/90$	x					
$1/90 \pm 1/90$	y	MR11	$\cdot/88$	11	11	MR1
$\cdot/90 \pm \cdot/90$	th					
$1/90 \pm 1/90$	x					
$1/90 \pm 1/90$	y	MR22	$\cdot/88$	11	11	MR2
$\cdot/90 \pm \cdot/90$	th					
$1/90 \pm 1/90$	x					
$1/90 \pm 1/90$	y	MR33	$\cdot/88$	11	11	MR3
$\cdot/90 \pm \cdot/90$	th					
$1/90 \pm 1/90$	x					
$1/90 \pm 1/90$	y	MR44	$\cdot/88$	11	11	MR4
$\cdot/90 \pm \cdot/90$	th					

با استفاده از دو تصویر که از یک دستگاه اخذ شدند و انتقال یکی از آن ها توسط برنامه کامپیوتری ، به ازای

x, y مقادیر ۱۱ میلی متر ، ۱۱ میلی متر و ۳۰ درجه به ترتیب برای CTI اعمال گردید و از تصاویر th و

و ه ترتیبی ————— و MRI4 ، MRI1، CT2 ، MRI2 ، MRI3
————— اویر ش

سپس بدست آمد MR44 و CT11، CT22، MR11، MR22، MR33
بیشینه کردن اطلاعات مقابل انجام

اولیه در ۳۰ مرحله بدست آمد x, y thy. گرفت

نتایج مربوط به میانگین پارامترهای : نتایج مربوط به قطعه بندی ضریب

، حساسیت، اختصاصیت و فاصله‌ی هوسدروف برای (Dice) دایس (Dice) میانگین ضریب دایس. نواحی مختلف تومور تعیین گردید برای نواحی کل تومور، هسته‌ی تومور و افزایش یافته به ترتیب ۰/۷۶

۰/۹۱ و میانگین حساسیت برای این نواحی به ترتیب ۰/۷۰، ۰/۰/۰
میانگین اختصاصیت برای نواحی. به دست آمد ۰/۸۰ و ۰/۰/۰
مختلف

فاصله‌ی هوسدروف برای کل تومور. ۰/۹۹ برآورد شد/یکسان و ۰/۸۲
این فاصله در ناحیه‌ی هسته‌ی تومور و افزایش یافته به ۰/۸
ترتیب

. ۰/۲ به دست آمد/ ۰/۴۳ و ۰/۴

ماتریس در هم ریختگی» نتایج : نتایج مربوط به طبقه بندی
از داده‌های آزمون در شکل ۳ آمده است (Confusion matrix)
این



این ماتریس، اطلاعات ارزشمندی در مورد برجسب های واقعی و در ارزیابی طبقه بند. پیش بینی شده توسط طبقه بند را ارائه می دهد مقادیر LGG و HGG جهت تعیین درجه ی تومور در دو گروه پارامترهای صحت، حساسیت، اختصاصیت، دقت موارد پیش بینی ، 98/94 ، 99/ ، 99/ ، 18/ ، 99/

۲۰ درصد حاصل شد/ و ۹۷ ۹۹/69

ها بحث

در این مطالعه، یک الگوریتم جدید به منظور طبقه بندی خودکار با استفاده از نتایج حاصل از MRI تومورهای گلیوما در تصاویر مرحله‌ی قطعه بندی تومور معرفی شد. مشابه مطالعه‌ی حاضر، از شبکه‌ی Deen و Naser در مطالعه‌ی و طبقه بندی بر مبنای شبکه‌ی و U-Net عصبی کانولوشنی بر مبنای در صورت گرفت LGG؛ اما به منظور تعیین درجه VGG16 مطالعه‌ی آنها یک مرحله پیش پردازش قبل از قطعه بندی شامل حذف شبکه‌ی عصبی. نواحی غیر ضروری تومور و ترمال سازی انجام گردید شامل چهار بلوک کانولوشنی در U-Net کانولوشنی بر مبنای ، به صورت VGG16 لایه‌ی آخر شبکه‌ی 3 قطعه بندی و با تغییر و لایه‌ی متراکم با یک 0/5 لایه‌ی مسطح، حذف تصادفی با فاکتور به کار بردند و دقت طبقه بندی LOG واحد در تعیین درجه‌ی تومور (۴) را گزارش کردند ۰/95.

و همکاران بدون مرحله‌ی قطعه بندی Kollerathu در مطالعه‌ی و با مرحله‌ی پیش پردازش شامل انتخاب برش با بزرگترین حجم تومور و انتخاب تنها دو برش بالایی و پایینی آن آموزش شبکه‌ی را حساسیت، اختصاصیت، دقت این شبکه جهت طبقه بندی. انجام دادند

در صد گزارش شد 99/4، ۹۱/۹۸، ۹۰/۹۰

این روش با نتایج .به طور کلی از تقارن نسبی مغز استفاده می کند
تقسیم بندی دستی دستی متخصصین مربوطه

.مقایسه شده است و در کل دقتی بیش از ۳۳٪ را از خود نشان داد
ویژگی بسیار خوب این روش

به طوری که .سرعت بسیار بالای آن در پیدا کردن تومور می باشد
پس از گذشت زمانی بین ۲ تا ۴ ثانیه
.تومور را سگمنت می نماید

گیری نتیجه

در مطالعه ی حاضر، روشی خودکار جهت طبقه بندی تومورهای بدون نیاز به نمونه برداری به MRI بر مبنای تصاویر LGG و HGG طبقه بند. روش تهاجمی استریو تاکتیک و صرف وقت ارائه گردید 16 VGG طراحی شده بر مبنای شبکه ی از پیش آموزش دیده را با دقت بالای LGG و HCG توانست تومورهای گلیوما . ۰۱ درصد طبقه بندی کند/۹۹

در پزشکی تصمیم گیری در رابطه با پیش گیری ، تشخیص و درمان یک از موارد کلیدی است و به سادگی

انجام پذیر نمی باشد و نیاز به روش های آزمایشگاهی و ابزارهای در صورتی که این آزمایش قابل اطمینان دارد

ها و ابزار ها موید یکدیگر باشند ، تصمیم گیری از قابلیت اطمینان در تشخیص .بیشتری برخوردار خواهد بود

تومورها ، ورم ها و خونریزی های عمقی در بافت هایی مانند مغز MRI انسان فقط تصویر برداری هایی مانند

راهگشا خواهند بود

از آنجا که این روش ها بر اساس حداقل خطای تخمینی از روی سیگنال های دریافتی باز سازی می شوند ، از

جنبه ی کیفی برخوردار هستند و از نظر کمی دارای ضعف می باشند جهت تقویت تصمیم گیری در تشخیص

توسط این روش ها پیشنهاد می شود این گونه تصاویر را با استفاده از به حداکثر رساندن اطلاعات متقابل بر هم

به تفسیر و عیب یابی در آنها پردازیم -منطبق نمود و

وبا (SVM) در این پایان نامه با استفاده از الگوریتم ماشین بردار پشتیبان برای PCA) تحلیل مولفه اصلی

در روش ما. استخراج ویژگی و طبقه بندی ناحیه تومور مغزی پرداختیم از شبکه عصبی که بسیار سریعتر است

.استفاده شده است که بسیار سریعتر از روش مبتنی بر ناحیه رویش است البته یک تفاوت عمده بین روش

پیشنهادی و روش ارایه شده توسط آنها این بود که روش پیشنهادی به طور کامل خودکار بود ولی روش های

میانگین عملکرد. آنها نیاز به انتخاب ناحیه شروع توسط کاربر داشت روش پیشنهادی در مرحله پاک کردن

۴۵٪ و در نمره شباهت /مجموعه در شاخص تشابه جاکارد برابر ۹۵ همچنین برای معیار.٪ بود 97/94دایس برابر

حساسیت ۹۸٪ و برای معیار ویژگی ۹۹بود که می توان از آنها قابلیت بالای مرحله پیش پردازش برای سگمنت

.کردن مغز و تولید یک خروجی مناسب برای مراحل بعد را نتیجه گرفت

50 تصاویری که در آزمایش های روش پیشنهادی استفاده شده است،
٪ حاوی تومور با تورم کم، ۳۰٪ حاوی

تومور با تورم متوسط و ۲۰٪ حاوی تومور با تورم زیاد بود و همچنین
این روش در مرحله کشف تومور با روش

سایه ها و همکاران که با استفاده از تقارن مغز اقدام به کشف تومور می
کند، با استفاده از تصاویری که در اختیار

نتایج این مقایسه نشان داد که روش پیشنهادی ما در .داشتیم مقایسه شد
مرحله کشف تومور ۹۵٪ از خود نشان

.روش سایه ها و همکاران ۸۷٪ موفقیت از خودش نشان داد .داد

1. Shobana ,G., Balakishnan ,r., Brain Tumor Diagnosis Form MRI Feature Analysis-A comparative Study,Innovations in Information ,Embedded And Communication System (ICIIECS) , 2015 International Conference on ,IEEE , 2015.
2. Shanmugapriya , B.; Ramakrishnan , T. , segmentation of brain Tumors In Computed Tomography Images using SVM Classifier, Electronics and Communication Systems(ICECS), 2014 International conference on, IEEE, 2014.
3. Sarathi , M.P. ;Ansari ,M.A.; Uher ,v.; Burget , R. ;Dutta ,M.K. ,Automated Brain Tumor Segmentation Using Novel Feature Point Detector And Seeded region Growing ,Telecommunications And Signal Processing (TSP), 2016 36thInternational conference on , IEEE, 2013.
4. Saraswathi , D. ; Sharmila , G.; Srinivasan , E . , An Automated Diagnosis System Using Wavelet Based SFTA Texture Features, Information Communication and System (ICICES) ,2014 International Conference on ,IEEE , 2014 .
5. Subashini , M.M.; Sahoo , S. k. , Brain Tumor Detection Using Pulse Coupled Neural Network (PCNN) and Back Propagation Network , Sustainable Energy and Intelligent Systems (SEISCON 2012) , IET Chennai 3rd International on IEEE ,2012 .
6. Anis LADGHAM , Ghada TORKHANI , Anis SAKLY , Abdellatif MTIBAA , “Modified Support Vector Machines for MR Brain Images Recognition “ , IEEE , CODIT , 13 , 2013 .
7. Ketan Machale , Hari Babu Nandpuru , Vivek Kapur , Laxi Kosta,“ MRI Brain Cancer Classification Using Hybrid Classifier (SVM – KN)’ , International Conference on Industrial Instrumentation and control (ICIC) , 2015 .
8. Hari Babu Nandpuru , S. S. Salankar , V .R . Bora , “ MRI Brain Cancer Classification Using Support Vector Machine” , IEEE Student’s Conference on Electical , Electronics and Computer Science , 2014 .
9. Parveen , Amritpa , “ Detection of Brain Tumor in MRI Images , Using Combination of Fuzzy C- Means and SVM “ , 2nd International Conference on Signal Processing and Integrated Network (SPIN) ,2015 .
10. M. Monica Subashini , Sara Kumar Sahoo , “ Brain Tumor Detection Using Pulse Coupled Neural Network (PCNN) AND Back Propagation network “ , Chennai and Vivekanandha College of technology For Women , Hird International Conference on Sustainable Energy and Intelligent System , 27-29 December , 2012 .
11. Abdullah , A. A.; Chize, B.S.; Nishio , y . , Implementation of an Improved Cellular Neural Network Algorithm For Tumor Detection , Biomedical Engineering (IC0BE) , 2012 International Conference on , IEEE , 2012 .

1. Goodenberger ML, Jenkins RB. Genetics of adult glioma. *Cancer Genet* 2012; 205(12): 613-21.
2. Işın A, Direkçioğlu C, Şah M. Review of MRI-based brain tumor image segmentation using deep learning methods. *Procedia Comput Sci* 2016;102: 317-24.
3. Bi WL, Hosny A, Schabath MB, Giger ML, Birkbak NJ, Mehrtash A, et al. Artificial intelligence in cancer imaging: clinical challenges and applications. *CA Cancer J Clin* 2019; 69(2): 127-57.
4. Naser MA, Deen MJ. Brain tumor segmentation and grading of lower-grade glioma using deep learning in MRI images. *Comput Biol Med* 2020; 121: 103758.
5. Kollerathu VA, Kesavadas C, Krishnamurthi G. A transfer learning based approach for automated grading of Gliomas using deep Residual Networks; 2018.
6. Rehman A, Naz S, Razzak MI, Akram F, Imran M. A deep learning-based framework for automatic brain

tumors classification using transfer learning. *Circuits, Syst Signal Pro* 2020; 39(2): 757-75.

7. Bakas S, Reyes M, Jakab A, Bauer S, Rempfler M, Crimi A, et al. Identifying the best machine learning algorithms for brain tumor segmentation, progression assessment, and overall survival prediction in the BRATS challenge. *arXiv preprint arXiv:181102629*; 2018.
8. Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation. In: Navab N, Hornegger J, Wells W, Frangi A, editor. *Medical image computing and*

computer-assisted intervention – MICCAI. Heidelberg, Germany: Springer; 2015.

9. Kermi A, Mahmoudi I, Khadir MT. Deep convolutional neural networks using U-Net for automatic brain tumor segmentation in multimodal MRI volumes. In: Crimi A, Bakas S, Kuijff H, Keyvan F, Reyes M, van Walsum T, editor. *Brainlesion: Glioma, multiple sclerosis, stroke and traumatic brain injuries*. Heidelberg, Germany: Springer; 2018.
10. Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:14091556*; 2014.